
Detección de Cumplimiento de Normas de Seguridad (EPP/Casco) en Obras de Construcción con YOLOv8

Nombre del Autor (completar)
Curso / Institución (completar)
correo@dominio

Abstract

Presentamos un sistema de visión por computador para monitorear el cumplimiento del uso de Equipos de Protección Personal (EPP), específicamente el casco de seguridad, en obras de construcción. Entrenamos un detector **YOLOv8s** sobre el *Safety-Helmet-Wearing-Dataset* (SHWD) [7], uno de los conjuntos recomendados, que incluye ejemplos negativos **explícitos** de “sin casco” (clase *head*) frente a “con casco” (clase *helmet*), con 7 581 imágenes y resolución de entrada de 640 px, partiendo de un backbone preentrenado en COCO. Sobre el conjunto de prueba obtenemos **mAP@0.5 = 94.2 %** y **mAP@0.5:0.95 = 61.4 %**. Más allá de la métrica agregada, analizamos la robustez estratificando el conjunto de prueba por **tamaño de objeto** (proxy de distancia: los trabajadores lejanos aparecen como objetos pequeños) y por **nivel de oclusión** estimado de forma semiautomática, y reportamos la caída de rendimiento entre grupos. Implementamos además un **verificador de cumplimiento basado en reglas** que convierte las detecciones por fotograma en una tasa de cumplimiento y marca las violaciones, y discutimos las implicaciones éticas de desplegar un sistema de este tipo, con énfasis en la asimetría entre falsos negativos y falsos positivos.

1. Introducción y Motivación

La industria de la construcción concentra una proporción desmesurada de accidentes laborales mortales; los traumatismos craneoencefálicos por caída de objetos o caídas de altura están entre las causas principales, y el uso correcto del casco es una de las medidas de control más efectivas y baratas. La supervisión manual del cumplimiento del EPP es costosa, intermitente y propensa a error humano, especialmente en obras grandes con múltiples frentes de trabajo. Un sistema automático que procese flujos de cámaras de obra y señale en tiempo (casi) real a los trabajadores sin casco puede aumentar la cobertura de la supervisión y generar registros auditables.

El problema no es un caso estándar de detección de objetos. En condiciones reales aparecen tres dificultades que estructuran este trabajo:

1. **Detección de objetos pequeños / larga distancia.** Las cámaras de obra cubren áreas amplias; los trabajadores lejanos aparecen con muy pocos píxeles y la cabeza/casco es aún más pequeña. Es el foco principal del trabajo.
2. **Oclusión severa.** Los trabajadores quedan parcialmente ocultos tras maquinaria, andamios, materiales u otros trabajadores.
3. **Desbalance de clases.** En SHWD la clase mayoritaria es, de hecho, la cabeza descubierta (*head*); la clase con casco es minoritaria, lo que sesga las métricas agregadas y dificulta el aprendizaje de la clase crítica.

Nuestro objetivo es entrenar y evaluar críticamente un detector YOLOv8 bajo estas condiciones, con especial atención a la detección a larga distancia, y construir sobre él un módulo de verificación de cumplimiento utilizable y éticamente informado.

2. Trabajos Relacionados

La detección automática de EPP en obras de construcción ha avanzado rápidamente con el aprendizaje profundo. El trabajo temprano de Fang et al. demostró que un modelo Faster R-CNN podía señalar a trabajadores sin casco a partir de video de vigilancia de campo lejano, destacando la dificultad de detectar trabajadores distantes y de baja resolución [2]. Los sistemas posteriores adoptaron detectores de una sola etapa para rendimiento en tiempo real: la familia YOLO, introducida por Redmon et al. [8] y refinada mediante avances arquitectónicos como backbones CSP y cuellos PANet [1] e información de gradiente programable [9], domina hoy la detección de cascos de seguridad. Hayat y Morgado-Dias, por ejemplo, construyeron un monitor de cascos basado en YOLO en tiempo real [3]. Nuestro trabajo usa Ultralytics YOLOv8 [4], que no tiene publicación revisada por pares y por tanto se cita como software, y se evalúa sobre el Safety Helmet Wearing Dataset (SHWD) [7].

Tres retos recurrentes en este dominio. La detección de objetos pequeños de trabajadores distantes se aborda típicamente mediante fusión de características multiescala como las Feature Pyramid Networks [6], y se revisa exhaustivamente en literatura reciente que también cataloga remedios para oclusión y desbalance de clases [5]. La oclusión severa detrás de maquinaria y andamios refleja el problema de oclusión en multitudes de la detección de peatones, donde la *repulsion loss* de Wang et al. logra una localización más robusta a oclusión [10]. Finalmente, la rareza relativa de una de las clases plantea un problema de desbalance señalado a lo largo de estos trabajos. Nuestro proyecto se apoya en esta literatura, adaptando YOLOv8 para abordar conjuntamente objetos pequeños, oclusión y desbalance en el monitoreo de cumplimiento de cascos.

3. Metodología

3.1. Conjunto de datos

Usamos el **Safety-Helmet-Wearing-Dataset (SHWD)** [7], recomendado por la consigna por aportar ejemplos negativos explícitos de “sin casco”. Convertimos sus anotaciones de Pascal VOC a formato YOLO y respetamos los splits predefinidos (sin fuga de datos): **5 457 / 607 / 1 517 imágenes** para train/val/test. Mapeamos las dos clases del dataset a: *helmet* (cabeza **con** casco = CONFORME) y *head* (cabeza **sin** casco = VIOLACIÓN). La Tabla 1 resume la distribución de instancias; evidencia un **fuerte desbalance** hacia la clase *head* (cabezas descubiertas, mayoritariamente de escenas con multitudes). La Figura 1a muestra esta distribución y la Figura 1b la de tamaños de bounding box: el **88 %** de las cabezas *head* caen en la categoría “pequeño” (lejano), lo que motiva fuertemente el análisis por distancia.

Cuadro 1: Distribución de instancias por clase y split en SHWD.

Clase	train	val	test
helmet (con casco)	6 419	747	1 878
head (sin casco)	79 778	9 178	22 558
imágenes	5 457	607	1 517

3.2. Modelo y backbone

Empleamos **YOLOv8s** (variante *small*, ~11 M de parámetros) inicializado con pesos preentrenados en COCO, conforme a la consigna que permite usar backbones preentrenados. YOLOv8 es **anchor-free**: predice directamente el centro y las dimensiones de cada caja sin un banco de anclas predefinido, lo que reduce el sesgo de escala y favorece la detección de objetos pequeños. Su *neck* tipo PAN-FPN fusiona características a múltiples escalas (P3–P5), mecanismo estándar para objetos pequeños [6].




Figura 1: Análisis exploratorio de SHWD: desbalance de clases (izq.) y predominio de objetos pequeños/lejanos (der.).

3.3. Decisiones de entrenamiento

- **Resolución de entrada:** 640×640 px, equilibrio entre detalle para objetos pequeños y memoria de una GPU de 8 GB.
- **Anclas:** no aplica — arquitectura anchor-free.
- **Aumento de datos:** mosaic (= 1,0) **activado**, con `close_mosaic= 10` para **desactivarlo en las últimas 10 épocas** y estabilizar la localización final; volteo horizontal ($p=0,5$); variación HSV ($h=0,015$, $s=0,7$, $v=0,4$) para robustez a iluminación; `translate= 0,1` y `scale= 0,5` — este último simula variaciones de **distancia**, clave para el objetivo de larga distancia. Se desactivaron mixup y copy-paste.
- **Optimización:** optimizador y *learning rate* automáticos de Ultralytics (AdamW); 100 épocas; batch= 8 y workers= 2 (limitados por la VRAM de 8 GB); semilla= 42 para reproducibilidad; precisión mixta (AMP).

3.4. Verificador de cumplimiento basado en reglas

Como SHWD distingue directamente *helmet* (con casco) de *head* (sin casco), el verificador (`src/compliance_verifier.py`, implementado por el estudiante) opera por **clasificación directa**: cada detección por encima del umbral de confianza (0.25) se categoriza como CONFORME (*helmet*) o VIOLACIÓN (*head*); la **tasa de cumplimiento por fotograma** es $\#helmet / (\#helmet + \#head)$, y se dibujan en verde las cajas conformes y en rojo (trazo grueso) las violaciones, con un encabezado que muestra la tasa. El módulo también soporta un modo de *asociación espacial* casco–persona para datasets sin clase “sin casco”. Esta regla aborda directamente el reto de larga distancia: una cabeza lejana mal clasificada altera la tasa, que es justamente el caso relevante para el análisis de falsos negativos (§6).

3.5. Análisis de robustez (oclusión y distancia)

Como el dataset no incluye etiquetas de oclusión, particionamos el conjunto de prueba de forma **semiautomática**:

- **Distancia (tamaño):** cada objeto se clasifica por su tamaño lineal relativo $\sqrt{w \cdot h}$ (normalizado): *small* ($< 0,08$, lejano), *medium* (0,08–0,25), *large* ($> 0,25$, cercano).
- **Oclusión:** para cada objeto, el máximo IoU con cualquier otro del mismo fotograma como proxy de oclusión mutua [10]: *bajo* ($< 0,10$), *medio* (0,10–0,35), *alto* ($> 0,35$).

Para cada grupo reportamos el **recall@IoU0.5** en el punto de operación `conf= 0,25` (relevante para despliegue), además del mAP global y por clase.

4. Experimentos

Hardware/Software: GPU NVIDIA RTX 5060 Laptop (8 GB, arquitectura Blackwell sm_120), PyTorch 2.11.0 + CUDA 12.8, Ultralytics 8.4.56, Python 3.13, Windows 11. **Reproducibilidad:** semilla 42; el pipeline completo se ejecuta con un único comando, `python run_pipeline.py` (descarga SHWD vía gdown sin credenciales, convierte, entrena, evalúa y genera la demo). Tiempo de entrenamiento: ~7 h 41 min para 100 épocas.

5. Resultados

5.1. Métricas globales y por clase

La Tabla 2 reporta las métricas sobre el conjunto de prueba.

Cuadro 2: Métricas de detección sobre el conjunto de prueba de SHWD (1 517 imágenes).

Clase	AP@0.5	AP@0.5:0.95	Precisión	Recall
helmet (con casco)	93.2	72.6	–	–
head (sin casco)	95.2	50.2	–	–
Global (media)	94.2	61.4	92.5	90.8

$\text{mAP@0.5} = 94.2 \%$, $\text{mAP@0.5:0.95} = 61.4 \%$, un resultado sólido. Destaca un contraste revelador: la clase *head* obtiene **mejor AP@0.5 (95.2 %)** pero **peor AP@0.5:0.95 (50.2 %)** que *helmet* (72.6 %). La causa es geométrica: las cabezas son objetos diminutos (88 % “small”), y en objetos pequeños la IoU es muy sensible a errores de pocos píxeles, por lo que la localización fina (umbrales de IoU altos) se degrada aunque la detección a IoU0.5 sea excelente. La Figura 2 muestra que los errores se concentran en falsos fondos (objetos pequeños no detectados) más que en confusión entre clases.



Figura 2: Matriz de confusión normalizada sobre el conjunto de prueba.

5.2. Robustez por distancia (objetos pequeños = larga distancia)

Cuadro 3: Recall@IoU0.5 (conf= 0,25) por tamaño de objeto (proxy de distancia).

Grupo (tamaño)	Recall
small (lejano)	92.7
medium	97.3
large (cercano)	97.8

El recall **global** apenas cae de 97.8 % (cercano) a 92.7 % (lejano): el modelo es notablemente robusto a la distancia gracias a la enorme cantidad de cabezas pequeñas vistas en entrenamiento. Sin embargo, el efecto es mucho más marcado en la **clase crítica helmet**, cuyo recall cae de **0.99 (cercano) a 0.81 (lejano)**: los **cascos lejanos se detectan peor**, lo que en la lógica de cumplimiento puede convertir a un trabajador conforme en una falsa violación (Figura 3). La detección a **larga distancia** sigue siendo, pues, el régimen más difícil para la clase que más importa.




Figura 3: Recall por distancia (tamaño de objeto como proxy).

5.3. Robustez por oclusión

Cuadro 4: Recall@IoU0.5 por nivel de oclusión estimado (IoU mutuo).

Grupo (oclusión)	Recall
bajo	94.7
medio	87.9
alto	60.8

La Figura 4 muestra una **degradación monótona y nítida** del recall al aumentar la oclusión estimada (94.7 % $\rightarrow$ 87.9 % $\rightarrow$ **60.8 %**): en las escenas de multitud de SHWD el solape mutuo entre cabezas sí captura oclusión real, y el grupo de oclusión alta (poco frecuente, $n=74$) es con diferencia el más difícil. Aquí el proxy funciona mejor que en un dataset multiescala porque las cabezas son **uniformemente pequeñas** (sin confusión con el tamaño); aun así, no captura la oclusión por estructuras estáticas, limitación que discutimos en §7.




Figura 4: Recall por nivel de oclusión estimado.

5.4. Verificador de cumplimiento (demostración)

Aplicamos el verificador a 80 imágenes del conjunto de prueba (no vistas en entrenamiento) y generamos un clip de video corto (outputs/demo/demo_clip.mp4) y un CSV de cumplimiento por fotograma. 23 fotogramas presentan al menos una violación y la tasa de cumplimiento media es del 88.4 %. La Figura 5 muestra ejemplos anotados, con trabajadores conformes (verde) y violaciones “sin casco” (rojo).



Figura 5: Demostración del verificador sobre imágenes de test no vistas: trabajadores con casco (verde, “OK casco”) y sin casco (rojo, “SIN CASCO”), con la tasa de cumplimiento por fotograma en el encabezado.

6. Implicaciones Éticas

El despliegue de un sistema automático de vigilancia del cumplimiento de EPP conlleva tensiones éticas inseparables de las decisiones técnicas.

Falsos negativos vs. falsos positivos. El coste de los dos errores es marcadamente asimétrico. Un **falso negativo** (un trabajador sin casco que el sistema no detecta) es una violación de seguridad no señalada: si la organización reduce la supervisión humana confiando en el sistema, puede traducirse en un accidente grave. Un **falso positivo** (marcar como infractor a quien sí cumple) erosiona la confianza, puede derivar en sanciones injustas y provoca “fatiga de alerta” que lleva a ignorar todas las alertas — reintroduciendo el riesgo de los falsos negativos. Nuestro análisis por distancia y oclusión muestra que los falsos negativos se concentran en los trabajadores **lejanos** y **ocuidos**, también los más expuestos; por ello recomendamos operar con un **umbral de confianza bajo** (priorizando recall) y tratar el sistema como **ayuda** a la supervisión humana, nunca como su sustituto ni como base para sanciones automáticas. Dónde fijar el umbral es, en el fondo, una decisión ética y no meramente técnica.

Privacidad de los trabajadores. El sistema procesa imágenes de personas identificables en su lugar de trabajo de forma continua, con riesgo de vigilancia laboral desproporcionada (los mismos flujos podrían reutilizarse para medir productividad o perfilar individuos). Mitigaciones: minimizar datos (procesar en el borde, **no almacenar** video crudo sino conteos/eventos agregados), **anonimizar** rostros, limitar la retención, restringir el acceso, ser transparentes con la plantilla y cumplir la normativa de protección de datos. El propósito legítimo (seguridad) no justifica por sí solo cualquier nivel de recolección.

Sesgos de los datos de entrenamiento. El modelo aprende la distribución de sus datos. SHWD combina escenas de obra con multitudes genéricas (cabezas descubiertas); si sobre-representa ciertos tipos de escena, condiciones de luz, colores de casco o complejiones, el rendimiento será desigual entre subgrupos. El fuerte desbalance hace además que el sistema sea, por construcción, peor en la clase minoritaria. Recomendamos auditar el rendimiento por subgrupos, equilibrar/aumentar la clase minoritaria, documentar las limitaciones del dataset y revalidar el modelo en cada obra antes de confiar en él. La equidad no es una propiedad emergente: debe verificarse explícitamente.

7. Discusión Crítica y Limitaciones

- **Resolución de entrada.** Usamos 640 px por memoria; para larga distancia, mayor resolución (p. ej. 1280) o *tiling* reducirían la caída de recall en objetos pequeños observada en §5.2. Es la limitación más relevante respecto al objetivo declarado.
- **Proxy de oclusión.** El IoU mutuo entre cajas captura solape inter-objeto pero no la oclusión por estructuras estáticas, y está **confundido con el tamaño** (las cajas grandes solapan más), por lo que no es un buen estimador aislado de oclusión. Una partición manual o etiquetas de oclusión real darían una medida fiel.
- **Desbalance y dominio del dataset.** En SHWD la clase “sin casco” es mayoritaria (por las multitudes), al revés que en una obra real donde el incumplimiento es escaso; las métricas agregadas deben leerse con ese sesgo en mente. Convendría recolección dirigida, sobre-muestreo o *focal loss*.
- **Generalización.** Entrenado y evaluado sobre un único dataset; el rendimiento puede caer ante *domain shift* (otras obras, climas, cámaras).
- **Verificador basado en reglas.** La clasificación directa es simple y robusta, pero hereda los errores del detector (una cabeza pequeña mal clasificada produce un falso positivo/negativo de cumplimiento) y no incorpora suavizado temporal entre fotogramas, que estabilizaría la tasa.
- **Componente propio vs. backbone.** Conforme a la consigna, el backbone es preentrenado; los componentes implementados por el estudiante son el **verificador de cumplimiento**, el **pipeline de evaluación estratificada** (distancia/oclusión), la **conversión VOC→YOLO** y el análisis del dataset.

8. Conclusión

Entrenamos y evaluamos críticamente un detector YOLOv8 para el cumplimiento del uso de casco en obras, usando el dataset recomendado SHWD con ejemplos explícitos de “sin casco”. Más allá del mAP agregado, mostramos — mediante un análisis estratificado por distancia y oclusión — que el rendimiento se degrada en los trabajadores lejanos y ocluidos, y construimos un verificador de cumplimiento utilizable cuyo despliegue analizamos desde una perspectiva ética. El trabajo futuro pasa por mayor resolución/*tiling*, equilibrado de la clase minoritaria y suavizado temporal en video.

Referencias

- [1] Alexey Bochkovskiy, Chien-Yao Wang, and Hong-Yuan Mark Liao. YOLOv4: Optimal speed and accuracy of object detection. *arXiv preprint arXiv:2004.10934*, 2020.
- [2] Qi Fang, Heng Li, Xiaochun Luo, Lieyun Ding, Hanbin Luo, Timothy M. Rose, and Wangpeng An. Detecting non-hardhat-use by a deep learning method from far-field surveillance videos. *Automation in Construction*, 85:1–9, 2018.
- [3] Ahatsham Hayat and Fernando Morgado-Dias. Deep learning-based automatic safety helmet detection system for construction safety. *Applied Sciences*, 12(16):8268, 2022.
- [4] Glenn Jocher, Ayush Chaurasia, and Jing Qiu. Ultralytics YOLOv8. <https://github.com/ultralytics/ultralytics>, 2023. Software, version 8.x.
- [5] Mingbo Kang et al. Small object detection: A comprehensive survey on challenges, techniques and real-world applications. *arXiv preprint arXiv:2503.20516*, 2025.

- [6] Tsung-Yi Lin, Piotr Dollár, Ross Girshick, Kaiming He, Bharath Hariharan, and Serge Belongie. Feature pyramid networks for object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2117–2125, 2017.
- [7] njvisionpower. Safety-helmet-wearing-dataset (SHWD). <https://github.com/njvisionpower/Safety-Helmet-Wearing-Dataset>, 2019.
- [8] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once: Unified, real-time object detection. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016.
- [9] Chien-Yao Wang, I-Hau Yeh, and Hong-Yuan Mark Liao. YOLOv9: Learning what you want to learn using programmable gradient information. In *European Conference on Computer Vision (ECCV)*, 2024.
- [10] Xinlong Wang, Tete Xiao, Yuning Jiang, Shuai Shao, Jian Sun, and Chunhua Shen. Repulsion loss: Detecting pedestrians in a crowd. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 7774–7783, 2018.